

使用知识图改进多跳问答
知识库嵌入

阿普尔夫·萨克塞纳* 阿迪泰·特里帕蒂*印度 帕萨·塔鲁克达尔
科学研究所,班加罗尔
{apoorvsaxena,aditayt,ppt}@iisc.ac.in

抽象的

知识图谱 (KG)是多关系的
由作为节点的实体和作为类型边的实体之间的关系组成的图。的目标
KG 问答 (KGQA) 任务
是回答自然语言提出的问题
超过公斤。多跳 KGQA 需要对 KG 的多个边进行推理
才能得出正确的答案。KG 通常是完整的,但存在许多
缺失的环节,这给 KGQA 带来了额外的挑战,尤其是对于

多跳 KGQA。最近关于多跳 KGQA 的研究尝试使用相关的外部文本来处理 KG 稀疏性,但这并不总是容易获得。在单独的一行中

研究中,KG嵌入方法已经
提出通过执行缺失链接预测来减少 KG 稀疏性。这样的 KG em 铺垫方法,尽管高度相关,

尚未探索多跳 KGQA
迄今为止。我们在本文中填补了这一空白并提出了 EmbedKGQA。EmbedKGQA 在执行多跳 KGQA 方面特别有效
在稀疏的 KG 上。EmbedKGQA也放松了
从预先指定的邻域中选择答案的要求,这是由先前的多跳 KGQA 强制执行的次优约束

方法。通过大量的实验
多个基准数据集,我们证明
EmbedKGQA 的有效性优于其他最先进的基线。

1 简介

知识图谱 (KG)是多关系的
由数百万个实体组成的图 (例如,San
何塞,加利福尼亚州等)以及之间的关系

*同等贡献
EmbedKGQA 的源代码位于
<https://github.com/mallabiisc/EmbedKGQA>

Question: What are the genres of movies written by Louis Mellis?
Answer : Crime




图 1:稀疏和不完整知识图谱中知识边缘图多跳 QA (KGQA) 面临的挑战:
边缘缺席有类型 (黑帮一号、犯罪)
不完整的 KG 使得回答变得更加困难
输入 NL 问题,可能作为 KGQA 模型
需要推理 KG 上更长的路径 (标记为
通过粗体边缘)。现有的多跳 KGQA 方法
还施加启发式邻域限制 (图中的阴影区域),这通常会得出真实答案
(本例中的犯罪)遥不可及。嵌入KGQA,
我们提出的方法克服了这些限制
在多跳期间利用输入 KG 的嵌入
KGQA。欲了解更多详细信息,请参阅图2和第4节。

他们 (例如,加利福尼亚州圣何塞市)。一些大型 KG 的示例
包括 Wikidata
(谷歌, 2013), DBpedia (Lehmann 等人, 2015),
Yago (Suchanek 等, 2007)和 NELL (Mitchell
等人, 2018)。问答胜过知识
图 (KGQA)在过去几年中已成为一个重要的研究领域
(Zhang 等人,
2018;孙等人, 2019a)。在 KGQA 系统中,给定
一个自然语言 (NL)问题和一个 KG,
正确答案是根据分析得出的
在 KG 的背景下提出的问题。
在多跳KGQA中,系统需要执行

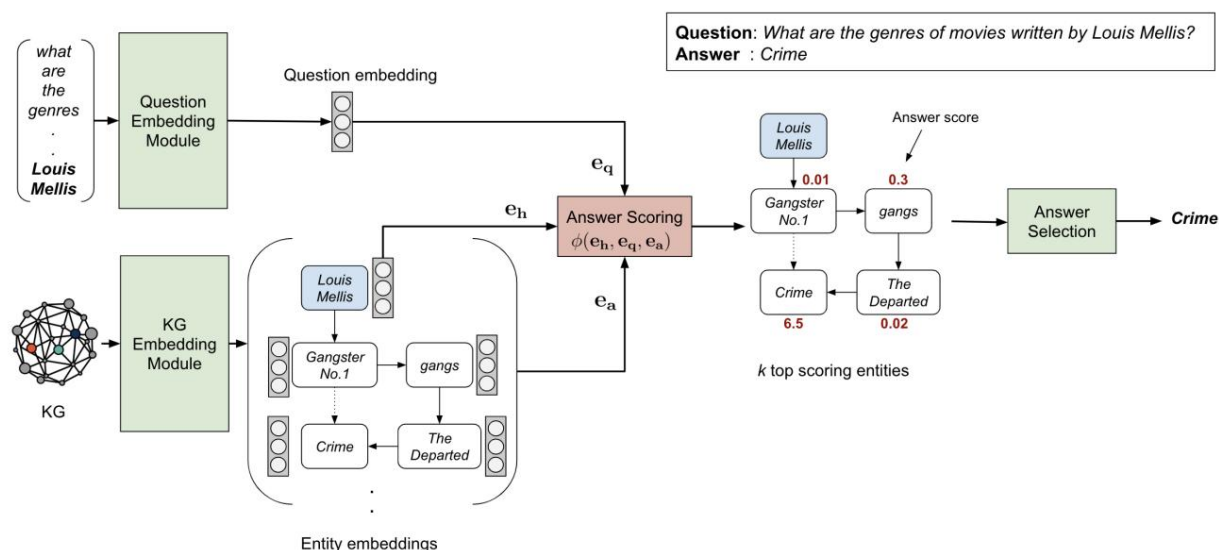


图 2: EmbedKGQA 概述,这是我们提出的基于知识图谱的多跳 QA (KGQA) 方法。

EmbedKGQA 具有三个模块:(1) KG 嵌入模块 (第4.2 节)学习输入 KG 中所有实体的嵌入,(2) 问题嵌入模块 (第4.3 节)学习问题的嵌入,以及 (3) Answer Selection模块 (第4.4 节)通过合并问题和关系相似度分数来选择最终答案。EmbedKGQA 对嵌入的使用使其在处理 KG 稀疏性方面更加有效。此外,由于 EmbedKGQA 将所有实体视为候选答案,因此它不会遇到现有多跳 KGQA 方法的有限邻域超出范围的问题。有关 EmbedKGQA 的详细说明,请参阅第4节。

对 KG 的多个边进行推理以推断出正确的答案。KG 通常是不完整的,这给 KGQA 系统带来了额外的挑战,特别是在多跳 KGQA 的情况下。最近的方法使用外部文本语料库来处理 KG稀疏性 (Sun et al., 2019a, 2018)。例如, (Sun et al., 2019a)中提出的方法从知识图谱构建特定于问题的子图,然后用支持文本文档对其进行增强。

然后将图 CNN (Kipf 和 Welling, 2016)应用于这个增强的子图以得出最终答案。不幸的是,相关文本语料库的可用性和识别本身就是一个挑战,限制了此类方法的广泛覆盖适用性。此外,此类方法还施加了预先指定的启发式邻域大小限制,从中可以得出真实答案

KGQA 模型必须对KG 上更长的路径进行潜在推理 (图中用粗体边缘标记)。此外,KGQA 模型强加了 3 跳的邻域大小,这使得真正的答案 Crime 遥不可及。

在另一项研究中,已有大量工作利用 KG 嵌入来预测 KG 中缺失的链接,从而降低KG 稀疏性 (Bordes 等人, 2013 年; Trouillon 等人, 2016 年; Yang 等人,2016 年)。, (2014a; Nickel 等人, 2011)。知识图谱嵌入方法学习知识图谱中实体和关系的高维嵌入,然后将其用于链接预测。尽管KG 嵌入方法具有很高的相关性,但它尚未用于多跳 KGQA。我们在本文中填补了这一空白。特别是,我们提出了EmbedKGQA,这是一种利用 KG 嵌入来执行多跳 KGQA 的新颖系统。我们在本文中做出以下贡献:

已选择。这通常会得出真正的答案
可供选择的模型范围。

为了说明这些观点,请考虑图 1 中所所示的示例。在此示例中, Louis Mellis 是输入 NL 问题中的头实体,而 Crime 是我们期望模型选择的真实答案。如果边缘有流派 (黑帮 No.

1,犯罪)存在于幼儿园,那么这个问题就可以很容易地回答。然而,由于知识图谱中缺少这条边,就像类似的不完整和稀疏知识图谱经常出现的情况一样,

1.我们提出了 EmbedKGQA,一种用于多跳 KGQA 任务的新方法。据我们所知,EmbedKGQA 是第一个使用 KG 嵌入来完成此任务的方法。

EmbedKGQA 在稀疏 KG 上执行多跳 KGQA时特别有效。

2. EmbedKGQA 放宽了从预先指定的本地选择 swer的要求

邻域,这是以前的方法对该任务施加的不良约束。

3.通过对多个真实世界数据集进行广泛的实验,我们证明了 Embed KGQA 相对于最先进基线的有效性。

我们提供了 EmbedKGQA 的源代码以鼓励可重复性。

2 相关工作

KGQA:在之前的工作中 (Li et al., 2018) TransE, (Bordes et al., 2013) 嵌入已被用来回答基于事实的问题。然而,这需要为每个问题进行真实关系标记,并且不适用于多跳问答。在另一项工作中 (Yih 等人, 2015) 和 (Bao 等人, 2016) 提出提取特定的子图来回答问题。(Bordes et al., 2014a) 中提出的方法,为头部实体生成的子图被投影到高维空间中以进行问答。记忆网络还被用来学习知识图谱中存在的事实的高维嵌入,以执行质量保证 (Bordes et al., 2015)。像 (Bordes et al., 2014b) 这样的方法在训练期间学习问题和相应三元组之间的相似性函数,并在测试时用所有候选三元组对问题进行评分。(Yang 等人, 2014b) 和 (Yang 等人, 2015) 利用基于嵌入的方法将自然语言问题映射到逻辑形式。像 (Dai et al., 2016; Dong et al., 2015; hao et al., 2017; Lukovnikov et al., 2017; Yin et al., 2016) 这样的方法利用神经网络学习评分函数来对候选者进行排名。有些作品 (Mohammed et al., 2017; Ture and Jojic, 2016) 将每个关系视为一个标签,并将模型 QA 任务视为一个分类问题。

扩展这些类型的多跳问答方法并非易事。

最近,有一些工作将文本语料库作为 KG 之外的知识源来回答有关 KG 的复杂问题 (Sun et al., 2018, 2019a)。当知识图谱不完整时,这种方法很有用。然而,这会导致 QA 系统变得更加复杂,并且文本语料库可能并不总是可用。

KG 补全方法:使用 KG 嵌入进行知识图谱中的链接预测已成为近年来的热门研究领域。

总体框架是为知识图谱中的一组三元组 (h, r, t) 定义一个分数函数,并以正确三元组的分数高于不正确三元组的分数的方式约束它们。

RESKAL (Nickel et al., 2011) 和 DistMult (Yang et al., 2015) 学习一个评分函数,其中包含头部实体和尾部实体向量之间的双线性乘积以及关系矩阵。ComplEx (Trouillon et al., 2016) 表示复空间中的实体向量和关系矩阵。SimpleE (Kazemi and Poole, 2018) 和 TuckER (Balazević et al., 2019) 分别基于正则多元 (CP) 分解 (Hitchcock, 1927) 和 Tucker de Composition (Tucker, 1966)。

TransE (Bordes et al., 2013) 将实体嵌入高维真实空间和关系作为头部和尾部实体之间的翻译。旋转E

(Sun et al., 2019b) 另一方面,在复杂空间中投影实体,并且关系被表示为复杂平面中的旋转。

ConvE (Dettmers et al., 2018) 利用卷积神经网络来学习头实体、尾实体和关系之间的评分函数。

InteractE (Vashishth 等人, 2019) 通过增加特征交互来改进ConvE。

3 背景

在本节中,我们正式定义知识图 (KG), 然后描述不完整 KG 上的链接预测任务。然后我们描述 KG 嵌入并解释 ComplEx 嵌入模型。

3.1 知识图谱

给定一组实体E和关系R,知识图G是一组三元组K,使得 $K \subseteq \text{三元组}$ 表示为 (h, r, t) , $E \times R \times E$ 。其中 $h, t \in E$ 分别表示主、客体实体, $r \in R$ 表示它们之间的关系。

3.2 链路预测

在链接预测中,给定不完整的知识图,任务是预测哪些未知链接是有效的。KG 嵌入模型通过评分函数 ϕ 来实现这一点,该函数分配一个分数 $s = \phi(h, r, t) \in \mathbb{R}$,该分数指示三元组是否为真,目标是能够正确地对所有缺失的三元组进行评分。

3.3 知识图嵌入对于每个 $e \in E$ 和 $r \in R$,知识图嵌入 (KGE) 模型生成 $e \in \mathbb{R}^d$

$e_r \in \mathbb{R}^{d_r}$ 其中 e_e 和 e_r 分别是 d_e 和 d_r 维向量。每种嵌入方法还具有一个评分函数 $\phi: E \times R \times E \rightarrow \mathbb{R}$ 将一些分数 $\phi(h, r, t)$ 分配给可能的三元组 (h, r, t) , $h, t \in E$ 和 $r \in R$ 。

模型的训练方式使得对于每个正确的三元组 $(h, r, t) \in K$ 和不正确的三元组 $(h, t) \in K$, 模型分配分数使得 $\phi(h, r, t) > 0$ 且 $\phi(h, t) < 0$ 。评分函数通常是 (e_h, e_r, e_t) 的函数。

3.3.1 ComplEx 嵌入 ComplEx

(Trouillon et al., 2016) 是一种张量分解方法, 它将关系和实体嵌入到复杂空间中。给定 $h, t \in E$ 和 $r \in R$, ComplEx 生成 $e_h, e_r, e_t \in \mathbb{C}^d$ 评分函数:

$$\phi(h, r, t) = \text{Re}(e_h, e_r, e_t)$$
$$= \sum_{k=1}^d \text{Re}(e_h^{(k)} \cdot e_r^{(k)} \cdot e_t^{(k)}) \quad (1)$$

使得对于所有真三元组 $\phi(h, r, t) > 0$, 对于假三元组 $\phi(h, r, t) < 0$ 。Re 表示复数的实部。

4 EmbedKGQA: 建议方法

在本节中, 我们首先定义 KGQA 的问题, 然后描述我们的模型。

4.1 问题陈述

设 E 和 R 分别为 KG 中所有实体和关系的集合, $K \subseteq E \times R \times E$ 是所有可用 KG 事实的集合。KGQA 中的问题涉及到, 给定自然语言问题 q 和问题中存在的主题实体 $e_h \in E$, 任务是提取正确回答问题 q 的实体 $e_t \in E$ 。

4.1.1 EmbedKGQA 概述

我们在数据集中不存在细粒度注释的环境中工作, 例如问题类型或确切的逻辑推理步骤。例如, co-actor 是 starred actor — 1 和 starred actor 关系的组合, 但我们的模型不需要此注释。

EmbedKGQA 使用知识图嵌入来回答多跳自然语言问题。首先, 它学习嵌入空间中 KG 的表示。然后给出一个问题吧

学习问题嵌入。最后它结合这些嵌入来预测答案。

在下面的章节中, 我们将介绍 EmbedKGQA 模型。它由 3 个模块组成:

- 1. KG Embedding Module 创建嵌入对于 KG 中的所有实体。
- 2. 问题嵌入模块查找问题的 e_m 嵌入
- 3. 答案选择模块减少了候选答案实体并选择最终的回答

4.2 KG 包埋模块

ComplEx 嵌入针对 KG 中的所有 $h, t \in E$ 和所有 $r \in R$ 进行训练, 使得 $e_h, e_r, e_t \in \mathbb{C}^d$ 实体嵌入用于学习头实体、问题和答案实体之间的三重评分函数。根据 QA 训练集中 KG 实体的覆盖范围, 此处学习的实体嵌入要么保持冻结, 要么允许在后续步骤中进行微调。

4.3 问题嵌入模块

该模块将自然语言问题 q 嵌入到固定维度向量 $e_q \in \mathbb{C}^d$ 中。这是使用前馈神经网络完成的, 该网络首先使用 RoBERTa (Liu 等人, 2019) 将问题 q 嵌入到 768 维向量中。然后通过 ReLU 激活的 4 个完全连接的线性层, 最后投影到复空间 \mathbb{C}^d 。

给定问题 q , 主题实体 $h \in E$ 和答案实体集 $A \subseteq E$, 它以如下方式学习问题嵌入:

$$\phi(e_h, e_q, e_a) > 0 \quad \forall a \in A$$

$$\phi(e_h, e_q, e_a) < 0 \quad \forall a \notin A$$

其中 ϕ 是 ComplEx 评分函数 (1), e_a, e_a 是在上一步中学习的实体嵌入。

对于每个问题, 用所有候选答案实体 $a \in E$ 计算得分 $\phi(\cdot)$ 。该模型是通过最小化得分的 sigmoid 与目标标签之间的二元交叉熵损失来学习的, 其中目标标签为 1 为正确答案, 否则为 0。当实体总数很大时进行标签平滑。

4.4 答案选择模块

在推理时,模型根据所有可能的答案 $a \in E$ 对 (头,问题)对进行评分。对于像 MetaQA 这样相对较小的 KG,我们只需选择得分最高的实体。

$$eans = \arg \max_{a \in E} \phi(eh, eq, ea)$$

然而,如果知识图很大,修剪候选实体可以显着提高 EmbedKGQA 的性能。修剪策略将在下一节中描述。

4.4.1 关系匹配

与 PullNet (Sun et al., 2019a)类似,我们学习一个评分函数 $S(r, q)$,它对给定问题 q 的每个关系 $r \in R$ 进行排名。令 hr 为关系 r 的嵌入, $q = (< s >, w_1, \dots, w_{|q|}, < /s >)$ 为问题 q 中输入到 RoBERTa的单词序列。

评分函数定义为RoBERTa最后一个隐藏层的最终输出 (hq)与关系 r (hr)的嵌入的点的sigmoid。

$$hq = \text{RoBERTa}(q)$$
$$S(r, q) = \text{sigmoid}(h_q \cdot h_r)$$

在所有关系中,我们选择那些得分大于0.5的关系,将其表示为集合 R_a 。对于到目前为止我们获得的每个候选实体 a (第 4.4 节),我们找到头实体 h 和 a 之间的最短路径中的关系。

令这组关系为 R_a 。现在,每个候选答案实体的关系分数被定义为其交集的大小。

$$\text{RelScore}_a = |R_a \cap R_q|$$

我们使用关系分数和 ComplEx 分数的线性组合来查找答案实体。

$$eans = \arg \max_{a \in N_h} \phi(eh, eq, ea) + \gamma * \text{RelScore}_a$$

其中 γ 是可调超参数。

5 实验细节

在本节中,我们首先描述评估我们的方法的数据集,然后解释实验设置和结果。

	训练开发测试	
MetaQA 1 跳	96,106	9,992 9,947
MetaQA 2 跳	118,948	
14,872 14,872	MetaQA 3 跳	114,196 14,274 14,274
WebQSP 2,998		100 1,639

表 1:MetaQA 和 WebQuestionsSP 数据集的统计数据。请参阅第 5.1节了解更多详细信息。

5.1 数据集

1. MetaQA (Zhang et al., 2018)数据集是一个大规模多跳 KGQA 数据集,主要包含超过 40 万个电影问题。它有 1 跳、2 跳和 3 跳问题。在我们的实验中,我们使用了问题的“普通”版本。除了QA 数据外,MetaQA 还提供了一个包含135k 个三元组、43k 个实体和 9 个关系的知识图谱。

2. WebQuestionsSP (tau Yih et al., 2016)是一个较小的 QA 数据集,包含 4,737 个问题。该数据集集中的问题是 1 跳和 2 跳问题,可通过 Free base KG回答。为了便于实验,我们将KB 严格限制为 Freebase 的子集,

包含We bQuestionsSP 问题中提到的任何实体2 跳以内的所有事实。我们进一步修剪它以仅包含数据集中提到的那些关系。这个较小的知识库有 180 万个实体和 570 万个三元组。

5.2 基线

我们将我们的模型与WebQuestionsSP 数据集的键值存储网络 (Miller 等人, 2016)、GraftNet (Sun等人, 2018)和 Pullnet (Sun 等人, 2019a)进行比较。对于 MetaQA 数据集,我们还与 VRN 进行比较 (Zhang et al., 2018)。

这些方法实现了多跳 KGQA,并且除了 VRN 之外,还使用额外的文本语料库来缓解KG 稀疏问题。

· VRN (Zhang et al., 2018)使用变分学习算法在 KG 上执行多跳 QA。

·键值内存网络 (KVMem) (Miller 等人, 2016)是第一个尝试通过用文本增强不完整的知识库来对其进行质量检查的模型之一。它维护一个存储 KB 事实和文本的内存表

模型	MetaQA KG-完整1 跳 2			元达KG-50		
	跳 3	跳 2	跳 1	跳 3	跳 2	跳 1
虚拟现实网络				-	-	-
移植网络	97.0	94.8	77.7	64.0 (91.5)	52.6 (69.5)	59.2 (66.4)
拉网	97.0	99.9	91.4	65.1 (92.4)	52.1 (90.4)	59.7 (85.2)
KV记忆法	96.2	82.7	48.9	63.6 (75.7)	41.8 (48.4)	37.6 (35.2)
EmbedKGQA (我们的)	97.5	98.8	94.8	91.8	70.3	

表 2:MetaQA 数据集的结果。所有基线结果均取自Sun 等人。 (2019a) 。我们考虑过全公斤(MetaQA KG-Full)和 50% 公斤(MetaQA KG-50)设置。该表中报告的数字是点击@1。括号中的数字对应于使用文本来增强不完整 KG 的设置 (MetaQA KG-50) 。欲了解更多详细信息,请参阅第5.3.1 节。

编码成键值对并将其用于恢复。

- GraftNet (Sun 等人, 2018)使用启发式方法创建一个特定于问题的子图,其中包含 KG 文本中的事实、实体和句子语料库,然后使用图 CNN 的变体 (Kipf 和 Welling, 2016)进行推理超过它。
- PullNet (Sun 等人, 2019a)还创建了它不是使用启发式方法,而是学习从数据中“提取”事实和句子,以创建更相关的子图

子图。它还使用了图 CNN 方法来进行推理。

完整的KG设置是最简单的设置用于 QA,因为数据集是在这样的环境中创建的答案总是存在于 KG 中,并且路径中没有缺失的链接。然而,它不是一个现实的设置,QA 模型应该也能够处理不完整的 KG。所以我们通过随机删除来模拟不完整的 KB KB 中三元组的一半 (我们随机丢弃概率 = 0.5 的事实)。我们称这个设置为 KG-50 ,我们称之为全公斤设定KG-Full 文本。

在下一节中我们将回答以下问题

问题:

Q1.可以使用知识图嵌入吗

执行多跳 KGQA? (第5.3 节)

Q2.当头部之间没有直接路径时,是否可以使用 EmbedKGQA 来回答问题

实体和答案实体? (第5.4 节)

Q3.答案选择模块对我们模型的最优性能有多大帮助?

(第5.5 节)

5.3 KGQA结果

在本节中,我们将我们的模型与 MetaQA 和 WebQuestionsSP 的基线模型数据集。

5.3.1 MetaQA分析

MetaQA 对数据集有不同的分区

1 跳、2 跳和 3 跳问题。满公斤时

设置 (MetaQA KG-Full)我们的模型可与 2 跳问题的最先进模型相媲美,并且

建立了 3 跳问题的最新技术。

EmbedKGQA 的表现与现有水平类似

如果是 1 跳问题,预计会因为答案节点直接连接到

头节点,它能够学习到相应的

从问题中嵌入关系。在另一

2 跳和 3 跳问题的表现

表明 EmbedKGQA 能够从相邻边推断出正确的关系,因为

KG 嵌入可以对关系的组成进行建模。 Pullnet 和 GraftNet 也表现类似

好吧,因为答案实体就在问题中

大多数时候都是子图。

我们还在不完整的KG 设置上测试了我们的方法,如上一节所述。在这里我们发现所有基线的准确性

与完整的 KG 设置相比显着降低,而 EmbedKGQA 达到了最先进的水平

表现。这是因为 MetaQA KG 相当

稀疏,43k 个实体只有 135k 个三元组。所以当 50% 的三元组被删除时 (如中所做的那样)

MetaQA KG-50),图变得非常稀疏

每个实体节点平均只有 1.66 个链接。

这引起了很多头实体节点的问题

有更长的路径 (>3)到达他们的答案

节点。因此,需要特定问题的模型

子图构造 (GraftNet、PullNet)无法回忆起生成的答案实体

模型	WebQSP KG-完整	WebQSP KG-50
KV记忆法	46.7	32.7 (31.6)
移植网络	66.4	48.2 (49.7)
拉网	68.1	50.1 (51.9)
嵌入KGQA	66.6	53.2

表 3:WebQuestionsSP 数据集上的性能。全部基线结果取自Sun 等人。 (2019a) 。这报告的值是hits@1。括号中的数字对应于使用文本来增强内容的设置
不完整的 KG (WebQSP KG-50)。更多细节请参阅第5.3.2 节。

子图,因此表现不佳。然而,他们的表现只有在包含之后才会提高
附加文本语料库。另一方面,EmbedKGQA 并不局限于子图,利用 KG em 基础的链接预测属性,EmbedKGQA 能够推断出关系
关于缺失的链接。

5.3.2 WebQuestionsSP分析
WebQuestionsSP 的数量相对较少
训练示例但使用较大的 KG (Freebase)
作为背景知识。这使得多跳 KGQA 更难。由于所有实体 KG不包含在训练集中,冻结在 KG 期间学习实体嵌入后
嵌入学习阶段 (第4.2 节)是必要的。 WebQuestionsSP 的结果 (表3)强调了这样一个事实:即使有少量的

训练例子 EmbedKGQA 可以学习不错
可以推断多跳的问题嵌入
回答问题所需的路径。
我们在 WebQSP KG-50 上的方法优于所有方法
包括 PullNet 在内的基线,它使用额外的文本信息,是最先进的模型。
尽管 WebQuestionsSP 的问题较少,EmbedKGQA 能够学习好的问题嵌入,可以推断 KG 中的任务链接。这
可以归因于这样一个事实:相关且必要的信息是通过 KG 捕获的

隐式嵌入。

5.4 对缺失链接的 KG 进行 QA
最先进的 KGQA 模型,例如 PullNet 和 GraftNet 需要头实体和知识中出现的答案实体
用图来回答问题。例如,在 PullNet,答案仅限于其中之一
提取的问题子图中存在的实体。
对于不完整的KG情况,只有50%
原始三元组存在,PullNet (Sun 等人,

模型	准确性
复杂的	20.1
嵌入KGQA	29.9

表 4:头实体与头实体之间没有链路的实验中 MetaQA 1 跳的 QA 结果
答案实体。我们将结果与 KG补全方法,其中黄金关系问题是已知的。详细信息在部分中提供
5.4.

2019a)报告 MetaQA 上的召回率为 0.544 1-跳跃数据集。这意味着只有 54.4%
问题中,所有答案实体都存在于提取的问题子图,这使得模型可以提出多少问题的硬性限制
在此设置下回答。
另一方面,EmbedKGQA 使用知识边缘图嵌入而不是本地化

子图来回答问题。它使用头部嵌入和问题嵌入,隐含地捕获了所有观察到的和头节点周围未观察到的链接。这是
可能是因为链接预测属性知识图嵌入。
因此与其他 QA 系统不同,即使有头部和答案实体之间没有路径,我们的模型应该能够回答以下问题:
KG 中有足够的信息
预测该路径 (见图1)。
我们设计了一个实验来测试我们模型的这种能力。对于 MetaQA 1-hop 数据集验证集中的所有问题,我们从知识图中删除了所有三元组

可以直接用来回答问题。
例如,给出问题 “什么语言 is [PK] in 在验证集中,我们删除了来自 KG 的三重 (PK,印地语) 。
该数据集还包含相同的释义问题,例如 “这部电影是什么语言的” [PK] 在 和 中所说的语言是什么
电影[PK] 。我们还删除了所有释义来自训练数据集的验证集问题
因为我们只想评估 KG 完成情况
我们模型的属性,而不是语言概括。

在这种情况下,我们期望模型依赖于仅在子图检索上实现0命中@1。
然而,我们的模型提供了明显更好的
在此设置下,29.9 次点击@1。这表明我们的模型可以捕获KG完成属性
Complex 嵌入并将其应用于答案

模型	网络QSP KG-全	网络QSP KG-50
EmbedKGQA {+	66.6	53.2
2 跳过滤} + 2 跳过滤,	72.5	51.8
- 关系匹配	58.7	48.5
{ 关系匹配}	48.1	47.4

表 5:该表显示了关系的重要性
匹配模块 (第4.4.1 节)以及 We bQuestionsSP 数据集中
EmbedKGQA 上基于邻域的过滤效果。 EmbedKGQA 本身
包含
关系匹配模块。在这里我们尝试看看
消除关系匹配模块的效果和
在应答期间添加 2 跳邻域过滤
选择。请参阅第5.5节了解更多详细信息。

本来不可能的问题。
进一步,如果我们知道对应的关系
对每个问题,然后是1-hop KG的问题
QA 与不完整的 KG 完成相同
知识图谱。使用相同的训练KG
上面并使用删除的三元组作为测试集,
我们使用 KG 嵌入进行尾部预测。这里
我们获得 20.1 次点击@1。较小的分数可以是
归因于 ComplEx 嵌入使用的事实
只有 KG,而我们的模型使用 QA 数据作为
好吧 这本身就代表了知识。我们的
模型首先在 KG 上进行训练,然后使用这些
嵌入来训练 QA 模型,因此它可以
利用 KG 和
质量保证数据。

5.5 答案选择模块的作用

我们通过消除关系匹配来分析答案选择模块 (第4.4 节)
对 WebQuestionsSP 数据集中 EmbedKGQA的影响
模块。此外,为了比较
将答案限制为知识图谱中邻域的其他方法 (Sun et al.
(2019a)、Sun et al. (2019a)、 Sun et al. (2019a)
(2018)),我们尝试将答案实体的候选日期集限制为仅头实
体的2 跳邻域。结果可以是

如表5所示。正如我们所见,关系匹配
对 Em bedKGQA 在 WebQSP KG-full 和 WebQSP 上
的性能都有显着影响
KG-50 设置。

此外,如前所述,WebQSP KG (自由基础子集)的实体
比 MetaQA多一个数量级 (MetaQA 中为 1.8M,而
MetaQA 为 134k)
并且可能的答案数量很大。因此减少 2 跳邻域的答案集

头部实体的业绩有所改善

以 WebQSP KG-Full 为例。然而,这
导致 WebQSP 性能下降
公斤-50。这是因为将答案限制为
不完整 KG 上的 2 跳邻域可能
导致候选人中不存在答案
(请参考图1)。
综上,我们发现关系匹配是
EmbedKGQA 的重要组成部分。更何况,我们
建议在答案选择期间进行 n 跳过滤
可以包含在 KG 的 EmbedKGQA 之上
相当完整。

六,结论

在本文中,我们提出了 EmbedKGQA,一种新颖的
多跳 KGQA 方法。 KG 通常是完整且稀疏的,这给多跳
KGQA 方法带来了额外的挑战。最近针对这个问题尝试通
过利用额外的方法来解决不完整性问题

文本语料库。然而,相关文本语料库的可用性通常是有限的,
从而减少了
此类方法的广泛适用性。在
一项单独的研究,提出了KG 嵌入方法来减少 KG 稀疏性

执行缺失链接预测。嵌入KGQA
利用 KG 嵌入的链接预测特性来缓解 KG 不完整性问题

不使用任何额外的数据。它训练KG
实体嵌入并用它来学习问题
嵌入,并且在评估过程中,它得分
(头实体,问题)再次配对所有实体,并且
选择得分最高的实体作为答案。
EmbedKGQA也克服了缺点
由于现有多跳 KGQA 方法施加的邻域大小限制有限。 Em
bedKGQA 在以下方面实现了最先进的性能

多个KGQA设置,提示链接
可以利用 KG 嵌入的预测特性来缓解 KG 不完整性问题

在多跳 KGQA 中。

致谢

我们要感谢匿名审稿人的建设性反馈,以及 Ashutosh
Kumar、Aditya Rastogi 和 Chandrahas 来自
印度科学研究所的富有洞察力的评论。这项研究部分由拨款
支持
来自英特尔和人力资源部
发展,印度政府。

参考

伊万娜·巴拉泽维 (Ivana Balazevi)、卡尔·艾伦 (Carl Allen) 和蒂莫西·M·霍斯佩戴尔斯 (Timothy M Hospedales)。 2019.塔克:张量分解用于知识图谱的补全。 arXiv 预印本 arXiv:1901.09590。

Junwei Bao, Nan Duan, Zhao Yan, Ming Zhou, and 赵铁军. 2016.基于约束的问题与知识图的转换。在诉讼程序中

COLING 2016,第26届国际会议
计算语言学:技术论文,
第 2503-2514 页。

安托万·博德斯、苏米特·乔普拉和杰森·韦斯顿。
2014a.使用子图嵌入来回答问题。 arXiv 预印本 arXiv:1406.3676。

安托万·博德斯、尼古拉斯·乌苏尼尔、苏米特·乔普拉和
杰森·韦斯顿。 2015.大型简单
用记忆网络回答。 arXiv 预印本
arXiv:1506.02075。

安东尼·博德斯、尼古拉斯·乌苏尼尔、阿尔贝托·加西亚·杜兰、杰
森·韦斯顿和奥克萨娜·雅赫年科。
2013.翻译嵌入以建模多关系数据。神经信息进展
处理系统,第 2787-2795 页。

安托万·博德斯、杰森·韦斯顿和尼古拉斯·乌苏尼尔。
2014b.使用弱监督嵌入模型进行开放式问答。在关于机器学习和知识发
现的欧洲联合会议上

数据库中,第 165-180 页。施普林格。

戴子航,李雷,徐伟。 2016. Cfo:条件聚焦神经问答
大规模的知识库。 arXiv 预印本
arXiv:1606.01994。

蒂姆·戴特默斯、帕斯夸莱·米勒维尼、庞图斯·斯特内托普、
和塞巴斯蒂安·里德尔。 2018. 卷积二维
知识图嵌入。三十二秒后
AAAI 人工智能会议。

Li Dong, Furu Wei, Ming Zhou, and Ke Xu.
2015. 使用多列卷积神经网络对 freebase 进行问答。协会第 53 届年
会记录

计算语言学和第七届自然语言处理国际联合会议 (第一卷:长论文),
第 260-269 页。

谷歌。 2013.Freebase 数据转储。 [https://
Developers.google.com/freebase/data](https://Developers.google.com/freebase/data)。

Yanchao Hao, Yuanzhe Zhang, Kang Liu, Shizhu He,
刘占义、吴华、赵军。 2017.一种结合全局交叉注意力的知识库问答端到
端模型

知识。计算语言学协会第 55 届年会记录
(第一卷:长论文),第 221-231 页。

弗兰克·L·希区柯克。 1927.张量的表达式
或作为乘积之和的多元多项式。数学与物理杂志,6 (1-4) :164–189。

赛义德·迈赫兰·卡泽米和大卫·普尔。 2018.简单
嵌入知识图中的链接预测。
神经信息处理系统进展,第 4284-4295 页。

托马斯·N·基普夫和马克斯·威灵。 2016.图卷积半监督分类

网络。 arXiv 预印本 arXiv:1609.02907。

延斯·莱曼、罗伯特·伊塞尔、马克斯·雅各布、安雅·詹奇、
迪米特里斯·康托科斯塔斯、巴勃罗·N·门德斯、塞巴斯蒂安
赫尔曼、穆罕默德·莫尔西、帕特里克·范·克莱夫、
索伦·奥尔等人。 2015.Dbpedia 从维基百科中提取的大规模、多语言
知识库。
语义网,6(2):167–195。

Dingcheng Li, Jingyuan Zhang, and Ping Li. 2018.
问题分类的表示学习
通过主题稀疏自动编码器和实体嵌入。
2018年IEEE大数据国际会议
(大数据),第 126-133 页。 IEEE。

Yinhan Liu, Myle Ott, Naman Goyal, Jingfei Du, Man dar
Joshi, Danqi Chen, Omer Levy, Mike Lewis,
卢克·泽特莫耶和维塞林·斯托亚诺夫。 2019.
Roberta:一种稳健优化的 bert 预训练方法。 arXiv 预印本 arXiv:
1907.11692。

丹尼斯·卢科夫尼科夫、阿雅·费舍尔、延斯·莱曼和
索伦·奥尔。 2017. 基于神经网络的单词和字符级别知识图谱问答。第 26
届国际会议论文集
万维网上的会议,第 1211-1220 页。
国际万维网会议指导
委员会。

亚历山大·米勒、亚当·费什、杰西·道奇、阿米尔·侯赛因·卡
里米、安托万·博德斯和杰森·韦斯顿。
2016.用于直接读取文档的键值存储网络。 arXiv 预印本 arXiv:
1606.03126。

Tom M. Mitchell,William W. Cohen,Estevan R. Hruschka
Jr.,Partha P. Talukdar,Bo Yang,Justin Beteridge,
Andrew Carlson,Bhavana Dalvi Mishra,
马特·加德纳、布莱恩·基西尔、贾扬特·克里希那穆西、
Ni Lao,Kathryn Mazaitis,Thahir Mohamed,Nda
pandula Nakashole,Emmanouil A. Platanios,Alan
里特·迈赫迪·萨马迪、伯尔·塞特尔斯、理查德·C.
王,Derry Wijaya,Abhinav Gupta,陈欣蕾,
阿布海尔·萨帕罗夫、马尔科姆·格里夫斯和乔尔
威灵。 2018.学习永无止境。交流。
ACM,61(5):103–115。

萨尔曼·穆罕默德、石鹏和林志颖。 2017年。
回答简单问题的强大基线
有和没有神经网络的知识图。
arXiv 预印本 arXiv:1712.01969。

马克西米利安·尼克尔、沃尔克·特雷斯普和汉斯-彼得
克里格。 2011.集体三向模型
多关系数据的学习。ICML,第 11 卷,第 809-816 页。

Fabian M Suchanek,Gjergji Kasneci 和 Gerhard
维库姆。 2007. Yago:语义知识的核心。
第16届国际会议论文集
万维网,第 697-706 页。 ACM。

海天孙、塔尼亚·贝德拉克斯-韦斯和威廉·W·科母鸡。 2019a. Pullnet:通过知识库迭代检索进行开放域问答

文本。 arXiv 预印本 arXiv:1904.09537。

Haitian Sun,Bhuwan Dhingra,Manzil Zaheer,Kathryn Mazaitis,Ruslan Salakhutdinov 和 William W Co hen。 2018. 使用开放域问答 知识库和文本的早期融合。 arXiv 预印本 arXiv:1809.00782。

Zhiqing Sun, Zhi-Hong Deng, Jian-Yun Nie, and Jian 唐。 2019b.旋转:通过复杂空间中的关系旋转来嵌入知识图 谱。 arXiv 预印本 arXiv:1902.10197。

西奥·特鲁永、约翰内斯·韦尔布尔、塞巴斯蒂安·里德尔、埃里克·高西 尔和纪尧姆·布沙尔。 2016.用于简单链接预测的复杂嵌入。在 国际机器学习会议中,页面

2071–2080。

莱德亚德·R·塔克 (Ledyard R Tucker) 1966.一些数学笔记 三模式因子分析。心理测量学, 31 (3) :279-311。

费尔汉·图雷和奥利弗·约伊奇。 2016.没必要 注意:简单的循环神经网络 工作! (用于回答“简单”问题)。 arXiv 预印本 arXiv:1606.05029。

Shikhar Vashishth,Soumya Sanyal,Vikram Nitin、 尼勒什·阿格拉沃尔和帕萨·塔鲁克达尔。 2019.In interacte: 改进基于卷积的知识 通过增加特征交互来图嵌入。 arXiv 预印本 arXiv:1911.00219。

Bishan Yang, Wen-tau Yih, Xiaodong He, Jianfeng 高,李登。 2014a.嵌入实体和 知识中的学习和推理关系 基地。 arXiv 预印本 arXiv:1412.6575。

Min-Chul Yang,Nan Duan,Ming Zhou 和 Hae Chang Rim。 2014b.联合关系嵌入 基于知识的问答。 2014 年实证方法会议论文集

自然语言处理 (EMNLP),第 645 页– 650。

杨民哲、李道吉、朴素英和林海昌。 2015.使用语义嵌入空间的基 于知识的问题。专家系统与应用,42(23) :9086–9104。

Scott Wen-tau Yih, Ming-Wei Chang, Xiaodong He, and Jianfeng Gao. 2015. Semantic parsing via 分阶段查询图生成:问答 与知识库。

Wen tau Yih、马修·理查森、克里斯托弗·米克、 张明伟、苏吉娜。 2016.价值 知识库问题的语义解析标记 回答。在ACL中。

Wenpeng Yin, Mo Yu, Bing Xiang, Bowen Zhou, and 欣里奇·舒茨。 2016.通过注意力卷积神经网络回答简单问题。 arXiv 预印本 arXiv:1606.03391。

张宇宇、戴汉军、Zornitsa Kozareva、Alexander J Smola 和 Le Song。 2018.知识图谱问答的变分推理。

第三十二届 AAAI 人工智能会议。